


Segundo Trabalho

Legenda Automática para Imagens

- **Objetivo:** Criar modelos capazes de legendar uma imagem automaticamente.
- **O que se deve fazer:** O objetivo deste trabalho é implementar e comparar três arquiteturas de Encoder-Decoder para a tarefa de legendagem automática de imagens. Todos os modelos utilizarão um *Encoder* idêntico, baseado em uma CNN pré-treinada do PyTorch (como ResNet ou VGG), cuja função é extrair um vetor de características visuais da imagem. A comparação focará no desempenho de três *Decoders* distintos, responsáveis por traduzir esse vetor visual em uma sequência textual: (1) um modelo LSTM, (2) um modelo GRU e (3) um modelo Transformador. O fluxo de operação do sistema é dividido em duas fases, como mostrado na imagem abaixo. Na primeira fase (*Encoder*), a imagem de entrada passa pela CNN, que gera um vetor de *features* (contexto visual) representando o conteúdo da imagem. Na segunda fase (*Decoder*), este vetor de contexto é fornecido como entrada inicial para o *Decoder* (LSTM, GRU ou Transformador). O *Decoder*, então, gera a legenda de forma sequencial, uma palavra de cada vez, utilizando o contexto da imagem e as palavras que ele acabou de gerar como entrada para prever a próxima palavra mais provável, repetindo o processo até que um token especial de fim de sentença seja gerado. **Faça comparações entre diferentes modelos pré-treinados para extração de *features*, veja como modelos diferentes impactam o seu modelo final.**



- **Dataset:** O *Flickr8k Image Dataset* é uma coleção de imagens e suas respectivas descrições textuais, projetada especificamente para ser um *benchmark* no desenvolvimento e avaliação de modelos de Visão Computacional e Processamento de Linguagem Natural. Ele contém 8.092 imagens selecionadas da plataforma *Flickr*. Cada imagem é pareada com cinco (5) legendas diferentes, escritas por humanos.
- **Onde baixar o dataset:** imagens e legendas. *Sugestão: faça o download desses links direto no notebook, ao invés de baixá-los localmente.*

- **Métrica a ser utilizada:** A métrica BLEU (*BiLingual Evaluation Understudy*) é uma métrica de avaliação para textos gerados por máquinas (como legendas ou traduções), medindo a similaridade entre o texto produzido por um modelo e um conjunto de textos de alta qualidade de referência. Seu funcionamento se baseia na contagem de N-gramas (sequências de N palavras) que se sobrepõem entre o candidato e as referências, usando uma precisão modificada para evitar a repetição excessiva de palavras e aplicando uma penalidade por brevidade para evitar que legendas muito curtas recebam pontuações artificialmente altas. O resultado final é um número entre 0 e 1, onde pontuações mais próximas de 1 indicam maior similaridade e, presumivelmente, maior qualidade do texto gerado. Essa métrica pode ser calculada usando os módulos correspondentes da biblioteca **TorchMetrics**. Abaixo vocês podem ver um código de exemplo do seu uso e a sua respectiva saída. Para mais detalhes consulte a referência: <https://docs.cloud.google.com/translate/docs/advanced/automl-evaluate>.

```
!pip install torchmetrics
import torch
from torchmetrics.functional.text import bleu_score

# Exemplo:

# Legendas gerada pelo modelo
preds = [
    # Predição 1:
    'um gato está no tapete',

    # Predição 2:
    'o homem e mulher estão andando',

    # Predição 3:
    'a grama é verde'
]

# Legendas de referência
target = [
    # Referências para a Predição 1:
    ['há um gato no tapete', 'um gato está no tapete', 'gato sentado no tapete'],

    # Referências para a Predição 2:
    ['um homem, uma mulher e um cachorro estão correndo na rua', 'duas pessoas e um cão caminham'],

    # Referências para a Predição 3:
    ['um campo de flores coloridas sob o sol', 'flores amarelas e roxas no campo verde']
]

bleu = bleu_score(preds, target)

print(f"Score BLEU Formatado (%): {bleu.item() * 100:.2f}%")
```

- **Tamanho dos grupos:** Até 3 alunos
- **Como o trabalho deve ser entregue:** Em um notebook jupyter completamente comentado e identificado com os passos da solução do problema e o porquê a estratégia/arquitetura/otimização dos parâmetros foram escolhidos. Citar as referências necessárias sempre que for o caso.
- **Quando deve ser entregue:** até 23 de novembro de 2025
- **Como deve ser entregue:** <https://forms.gle/3jaAsyGWoozJZJQz7>